

第 2 章 Convex Sets 笔记

2026 年 7 月 9 日

Chapter 2 · Convex sets notes

优化与基本形式

Affine sets 仿射集

Convex sets 凸集

Convex cones 凸锥

线性分数函数

分离与支撑超平面



1 优化问题基本形式

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq b_i, \quad i = 1, 2, \dots, m \\ & && x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^n \end{aligned}$$

Convex / non-convex $\rightarrow$ 简单 / 不简单

重点章节: 2、3、4、5、9、10

2 Affine Sets 仿射集

2.1 直线 (Line)

设 $x_1, x_2 \in \mathbb{R}^n$, $\theta \in \mathbb{R}$, 则

$$y = \theta x_1 + (1 - \theta)x_2 = x_2 + \theta(x_1 - x_2)$$

2.2 线段 (Line Segment)

$$y = \theta x_1 + (1 - \theta)x_2, \quad 0 \leq \theta \leq 1$$

定义 1: 仿射集

集合 $C \subseteq \mathbb{R}^n$ 称为**仿射集** (Affine Set), 当且仅当对任意 $x_1, x_2 \in C$ 和任意 $\theta \in \mathbb{R}$, 都有

$$\theta x_1 + (1 - \theta)x_2 \in C.$$

定义 2: 仿射组合

设 $x_1, x_2, \dots, x_k \in C$, $\theta_1, \theta_2, \dots, \theta_k \in \mathbb{R}$ 且满足

$$\sum_{i=1}^k \theta_i = 1$$

则称

$$\sum_{i=1}^k \theta_i x_i$$

为 $x_1, x_2, \dots, x_k$ 的一个**仿射组合** (Affine Combination)。

定理 3: 仿射组合封闭性

若 C 是仿射集, 则 C 中任意有限个点的仿射组合仍属于 C 。

2.3 仿射组合的封闭性 (三点示例)

设 $x_1, x_2, x_3 \in C$, $\theta_1, \theta_2, \theta_3 \in \mathbb{R}$ 且 $\theta_1 + \theta_2 + \theta_3 = 1$, 则

$$\theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 \in C.$$

2.4 仿射集的平移表示

设 C 为仿射集, $x_0 \in C$, 定义

$$V = C - x_0 = \{x - x_0 \mid x \in C\}.$$

则 V 是线性子空间 (即对任意 $u_1, u_2 \in V$, $\alpha, \beta \in \mathbb{R}$, 都有 $\alpha u_1 + \beta u_2 \in V$)。

简证. 任取 $u_1, u_2 \in V$, 则存在 $x_1, x_2 \in C$ 使得 $u_1 = x_1 - x_0$, $u_2 = x_2 - x_0$ 。于是

$$\alpha u_1 + \beta u_2 = [\alpha x_1 + \beta x_2 + (1 - \alpha - \beta)x_0] - x_0.$$

因为 C 是仿射集, 上式括号内向量属于 C , 故 $\alpha u_1 + \beta u_2 \in V$ 。 □

2.5 线性方程组的解集是仿射集

例子 4: 线性方程组解集是仿射集

设

$$C = \{x \in \mathbb{R}^n \mid Ax = b\}, \quad A \in \mathbb{R}^{m \times n}, \quad b \in \mathbb{R}^m.$$

则 C 是仿射集。

证明. 任取 $x_1, x_2 \in C$, $\theta \in \mathbb{R}$, 则

$$A(\theta x_1 + (1 - \theta)x_2) = \theta b + (1 - \theta)b = b.$$

因此 $\theta x_1 + (1 - \theta)x_2 \in C$. □

注解 5: 解集的平移表示

若 $x_0 \in C$ (即 $Ax_0 = b$), 则

$$V = C - x_0 = \{y \mid Ay = 0\},$$

即 V 是齐次线性方程组的解空间 (零空间)。

2.6 仿射包 (Affine Hull) ——最小仿射集

定义 6: 仿射包

任意集合 $C \subseteq \mathbb{R}^n$ 的**仿射包** (Affine Hull) 定义为

$$\text{aff } C = \left\{ \sum_{i=1}^k \theta_i x_i \mid x_i \in C, \theta_i \in \mathbb{R}, \sum_{i=1}^k \theta_i = 1 \right\}.$$

定理 7: 仿射包最小性

$\text{aff } C$ 是包含 C 的最小仿射集: 即若 S 是任意仿射集且 $C \subseteq S$, 则 $\text{aff } C \subseteq S$ 。

3 Convex Sets 凸集

定义 8: 凸集

集合 $C \subseteq \mathbb{R}^n$ 称为**凸集** (Convex Set), 当且仅当对任意 $x_1, x_2 \in C$ 和任意 $\theta \in [0, 1]$, 都有

$$\theta x_1 + (1 - \theta)x_2 \in C.$$

注解 9: 仿射集与凸集关系

仿射集是凸集的特例 (因为仿射集对任意 $\theta \in \mathbb{R}$ 封闭, 而凸集只需 $\theta \in [0, 1]$)。

定义 10: 凸组合

设 $x_1, x_2, \dots, x_k \in C$, $\theta_1, \theta_2, \dots, \theta_k \in \mathbb{R}$ 满足

$$\theta_i \geq 0, \quad \sum_{i=1}^k \theta_i = 1,$$

则称 $\sum_{i=1}^k \theta_i x_i$ 为 $x_1, \dots, x_k$ 的一个**凸组合** (Convex Combination)。

定理 11: 凸组合封闭性判别

C 是凸集当且仅当 C 中任意有限个点的凸组合仍属于 C 。

3.1 凸包 (Convex Hull) —— 最小凸集

定义 12: 凸包

任意集合 $C \subseteq \mathbb{R}^n$ 的凸包 (Convex Hull) 定义为

$$\text{conv } C = \left\{ \sum_{i=1}^k \theta_i x_i \mid x_i \in C, \theta_i \geq 0, \sum_{i=1}^k \theta_i = 1 \right\}.$$

定理 13: 凸包最小性

$\text{conv } C$ 是包含 C 的最小凸集。

4 Convex Cones 凸锥

定义 14: 凸锥

集合 $C \subseteq \mathbb{R}^n$ 称为凸锥 (Convex Cone)，当且仅当

$$x \in C, \theta \geq 0 \implies \theta x \in C.$$

(等价地: 对任意 $x_1, x_2 \in C$ 和 $\theta_1, \theta_2 \geq 0$, 都有 $\theta_1 x_1 + \theta_2 x_2 \in C$)

定义 15: 凸锥组合

设 $x_1, \dots, x_k \in C$, $\theta_1, \dots, \theta_k \geq 0$, 则

$$\sum_{i=1}^k \theta_i x_i$$

称为凸锥组合。

注解 16: 凸锥包记号

凸锥包 (最小凸锥) 是包含 C 的最小凸锥, 记为 $\text{cone } C$ 或 $\text{convcone } C$ 。

5 几种重要的凸集

定义 17: 重要凸集示例

以下均为凸集 (部分同时也是仿射集):

- $\mathbb{R}^n$ 整个空间
- $\mathbb{R}^n$ 的任意子空间 (subspace)
- 任意直线 (line)

- 任意线段 (line segment) (凸集, 但一般不是仿射集)
 - 任意射线 (ray): $\{x_0 + \theta v \mid \theta \geq 0\}$, 其中 $x_0 \in \mathbb{R}^n$, $v \in \mathbb{R}^n$
- 任意子空间既是凸集也是仿射集。

6 超平面与半空间

6.1 超平面 (Hyperplane)

$$\{x \in \mathbb{R}^n \mid a^T x = b\}, \quad a \in \mathbb{R}^n \setminus \{0\}, b \in \mathbb{R}$$

6.2 半空间 (Halfspace)

$$\{x \in \mathbb{R}^n \mid a^T x \leq b\}$$

(同理 $\{x \mid a^T x \geq b\}$ 也是半空间)

注解 18: 超平面与半空间性质

超平面是仿射集, 半空间是凸集 (但不是仿射集)。

7 球与椭球

7.1 欧氏球 (Euclidean Ball)

$$\mathcal{B}(x_c, r) = \{x \in \mathbb{R}^n \mid \|x - x_c\|_2 \leq r\} = \left\{x \mid \sqrt{(x - x_c)^T (x - x_c)} \leq r\right\}$$

凸性证明. 任取 $x_1, x_2 \in \mathcal{B}(x_c, r)$, $\theta \in [0, 1]$, 则

$$\begin{aligned} \|\theta x_1 + (1 - \theta)x_2 - x_c\|_2 &= \|\theta(x_1 - x_c) + (1 - \theta)(x_2 - x_c)\|_2 \\ &\leq \theta\|x_1 - x_c\|_2 + (1 - \theta)\|x_2 - x_c\|_2 \\ &\leq \theta r + (1 - \theta)r = r. \end{aligned}$$

故 $\theta x_1 + (1 - \theta)x_2 \in \mathcal{B}(x_c, r)$ 。

□

7.2 椭球 (Ellipsoid)

$$\mathcal{E} = \{x \in \mathbb{R}^n \mid (x - x_c)^T P^{-1} (x - x_c) \leq 1\}, \quad P \in \mathbf{S}_{++}^n$$

($\mathbf{S}_{++}^n$ 表示正定矩阵)

特别地, 当 $P = r^2 I_n$ 时, 椭球退化为欧氏球。

注解 19: 奇异值补充

若 $P = A^T A$ (A 可逆), 则可通过奇异值分解表示椭球形状。

7.3 正定矩阵 (Positive Definite)

设 $A \in \mathbb{R}^{n \times n}$, 若对任意 $x \neq 0$ 都有 $x^T A x > 0$, 则称 A 为**正定矩阵**。

1. 其特征值 $\lambda_i(A) > 0$ (全正)
2. 存在 Cholesky 分解: $A = LL^T$ (L 为下三角矩阵)
3. 函数 $f(x) = x^T A x$ 是严格凸函数 (strictly convex)

8 多面体 (Polyhedron)

定义 20: 多面体

集合 $P \subseteq \mathbb{R}^n$ 称为**多面体** (Polyhedron), 若它可表示为有限个半空间与超平面的交集:

$$P = \{x \in \mathbb{R}^n \mid a_j^T x \leq b_j, j = 1, \dots, m; \quad c_j^T x = d_j, j = 1, \dots, p\}$$

其中 $a_j, c_j \in \mathbb{R}^n$, $b_j, d_j \in \mathbb{R}$ 。

等价地, $P = \{x \mid Ax \leq b, Cx = d\}$, 其中

$$A = \begin{bmatrix} a_1^T \\ \vdots \\ a_m^T \end{bmatrix}, \quad C = \begin{bmatrix} c_1^T \\ \vdots \\ c_p^T \end{bmatrix}.$$

8.1 单纯形 (Simplex)

在 $\mathbb{R}^n$ 中选取 $k+1$ 个仿射无关的点 $v_0, v_1, \dots, v_k \in \mathbb{R}^n$, 则它们的**单纯形**定义为

$$C = \text{conv}\{v_0, v_1, \dots, v_k\} = \left\{ \sum_{i=0}^k \theta_i v_i \mid \theta_i \geq 0, \sum_{i=0}^k \theta_i = 1 \right\}.$$

定理 21: 单纯形与多面体

单纯形一定是多面体。

证明. 设 $x \in C$, 则存在 $\theta_i \geq 0, \sum \theta_i = 1$ 使得 $x = \sum_{i=0}^k \theta_i v_i$ 。令 $y = x - v_0 = \sum_{i=1}^k \theta_i (v_i - v_0)$, 则

$$y = B\theta', \quad \theta' = (\theta_1, \dots, \theta_k)^T, \quad B = [v_1 - v_0, \dots, v_k - v_0] \in \mathbb{R}^{n \times k}.$$

因为 $v_0, \dots, v_k$ 仿射无关, 所以 $\text{rank}(B) = k$ 。存在矩阵 A_1, A_2 使得

$$A_1 B = I_k, \quad A_2 B = 0.$$

从而

$$A_1 y = \theta' \geq 0, \quad A_2 y = 0.$$

代回 $x = y + v_0$ 可得

$$A_1(x - v_0) \geq 0, \quad A_2(x - v_0) = 0,$$

即 x 满足一组线性不等式与等式约束, 因此 C 是多面体。 □

9 保持凸性的运算 (Operations that preserve convexity)

9.1 交集 (Intersection)

若 S_1, S_2 为凸集, 则 $S_1 \cap S_2$ 为凸集。更一般地, 若对任意 $\alpha \in A$, S_α 均为凸集, 则

$$\bigcap_{\alpha \in A} S_\alpha$$

仍为凸集。

10 仿射函数 (Affine Functions)

定义 22: 仿射函数

函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 称为**仿射函数** (Affine), 当且仅当存在 $A \in \mathbb{R}^{m \times n}$ 和 $b \in \mathbb{R}^m$ 使得

$$f(x) = Ax + b.$$

定理 23: 仿射像保持凸性

设 $S \subseteq \mathbb{R}^n$ 为凸集, $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 为仿射函数, 则像集

$$f(S) = \{f(x) \mid x \in S\}$$

为凸集。

定理 24: 逆像 (Inverse image)

设 $g: \mathbb{R}^k \rightarrow \mathbb{R}^n$ 为仿射函数, $S \subseteq \mathbb{R}^n$ 为凸集, 则逆像

$$g^{-1}(S) = \{x \in \mathbb{R}^k \mid g(x) \in S\}$$

为凸集。

11 缩放与移位 (Scaling and Translation)

缩放 (scaling) 和移位 (translation) 运算保持凸性:

- 若 S 为凸集, $\lambda \geq 0$, 则 $\lambda S = \{\lambda x \mid x \in S\}$ 为凸集;
- 若 S 为凸集, $y \in \mathbb{R}^n$, 则 $S + y = \{x + y \mid x \in S\}$ 为凸集。

例子 25: 凸集的和与笛卡尔积

设 S_1, S_2 为凸集, 则

$$S_1 + S_2 = \{x + y \mid x \in S_1, y \in S_2\}$$

和

$$S_1 \times S_2 = \{(x, y) \mid x \in S_1, y \in S_2\}$$

均为凸集。

12 半正定、LMI 与椭球（补充）

12.1 线性矩阵不等式（Linear Matrix Inequality, LMI）

设 $A_1, A_2, \dots, A_n, B \in \mathbf{S}^m$ (m 阶对称矩阵)，定义仿射映射

$$\mathcal{A}(x) = \sum_{i=1}^n x_i A_i.$$

则线性矩阵不等式（LMI）的解集为

$$\{x \in \mathbb{R}^n \mid \mathcal{A}(x) \preceq B\}$$

（其中 $\preceq$ 表示 $B - \mathcal{A}(x)$ 是半正定矩阵）。

定理 26: LMI 的解集是凸集

LMI 的解集是凸集。

证明. 定义仿射变换 $f(x) = B - \mathcal{A}(x)$ ，则

$$\{x \mid \mathcal{A}(x) \preceq B\} = \{x \mid f(x) \succeq 0\} = f^{-1}(\mathbf{S}_+^m),$$

其中 $\mathbf{S}_+^m$ 是半正定锥，是凸集。因为仿射函数的逆像保持凸性，所以该解集为凸集。 $\square$

12.2 椭球的另一种证明（通过单位球的仿射映射）

单位球是凸集：

$$\{u \in \mathbb{R}^n \mid \|u\|_2 \leq 1\}.$$

考虑严格仿射映射

$$f(u) = P^{1/2}u + x_c,$$

其中 $P \in \mathbf{S}_{++}^n$ （正定矩阵）。则椭球可表示为

$$\mathcal{E} = f(\{u \mid \|u\|_2 \leq 1\}).$$

因为仿射函数像集保持凸性，故椭球是凸集。

等价地，若 $x = P^{1/2}u + x_c$ ，则 $u = P^{-1/2}(x - x_c)$ ，代入单位球不等式得

$$(x - x_c)^T P^{-1}(x - x_c) \leq 1.$$

13 透视函数（Perspective Function）

定义 27: 透视函数

透视函数 $P: \mathbb{R}^{n+1} \rightarrow \mathbb{R}^n$ 定义为

$$P(x, t) = \frac{x}{t},$$

定义域为 $\text{dom } P = \mathbb{R}^n \times \mathbb{R}_{++}$ ($t > 0$)。

定理 28: 透视函数保持 (像的) 凸性

透视函数保持凸性: 若 $C \subseteq \text{dom } P$ 是凸集, 则 $P(C)$ 是凸集。

证明. 任取 $x, y \in C$, $x = (\tilde{x}, x_{n+1})$, $y = (\tilde{y}, y_{n+1})$, $x_{n+1} > 0$, $y_{n+1} > 0$, $\theta \in [0, 1]$ 。考虑线段上的点:

$$z = \theta x + (1 - \theta)y = (\theta\tilde{x} + (1 - \theta)\tilde{y}, \theta x_{n+1} + (1 - \theta)y_{n+1}).$$

则

$$P(z) = \frac{\theta\tilde{x} + (1 - \theta)\tilde{y}}{\theta x_{n+1} + (1 - \theta)y_{n+1}} = \frac{\theta x_{n+1} \frac{\tilde{x}}{x_{n+1}} + (1 - \theta)y_{n+1} \frac{\tilde{y}}{y_{n+1}}}{\theta x_{n+1} + (1 - \theta)y_{n+1}} = \mu P(x) + (1 - \mu)P(y),$$

其中

$$\mu = \frac{\theta x_{n+1}}{\theta x_{n+1} + (1 - \theta)y_{n+1}} \in [0, 1].$$

因此 $P(z)$ 是 $P(x)$ 与 $P(y)$ 的凸组合, 故 $P(C)$ 为凸集。 □

14 线性分数函数 (Linear Fractional Function)**定义 29: 线性分数函数**

设 $g: \mathbb{R}^n \rightarrow \mathbb{R}^{m+1}$ 为仿射函数:

$$g(x) = \begin{bmatrix} A \\ c^T \end{bmatrix} x + \begin{bmatrix} b \\ d \end{bmatrix}, \quad A \in \mathbb{R}^{m \times n}, c \in \mathbb{R}^n, b \in \mathbb{R}^m, d \in \mathbb{R}.$$

则线性分数函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 定义为透视函数与仿射函数的复合:

$$f(x) = P(g(x)) = \frac{Ax + b}{c^T x + d},$$

定义域为

$$\text{dom } f = \{x \in \mathbb{R}^n \mid c^T x + d > 0\}.$$

定理 30: 线性分数函数保持 (像的) 凸性

线性分数函数是凸集到凸集的映射 (即若 $C \subseteq \text{dom } f$ 是凸集, 则 $f(C)$ 是凸集)。

例子 31: 概率论中的应用

设 U, V 是两个离散随机变量, 取值分别为 $\{1, 2, \dots, n\}$ 和 $\{1, 2, \dots, m\}$ 。联合概率 $P_{ij} = P(U = i, V = j)$, 条件概率 $f_{ij} = P(U = i \mid V = j)$ 。则

$$f_{ij} = \frac{P_{ij}}{\sum_{k=1}^n P_{kj}} = \frac{P_{ij}}{P(V = j)}.$$

这正是线性分数函数的形式 (分子为仿射映射, 分母为线性形式)。

15 分离超平面与支撑超平面

15.1 分离超平面 (Separating Hyperplane)

定理 32: 分离超平面定理

设 $C, D \subseteq \mathbb{R}^n$ 是两个非空凸集, 且 $C \cap D = \emptyset$, 则存在 $a \in \mathbb{R}^n \setminus \{0\}$ 和 $b \in \mathbb{R}$ 使得

$$a^T x \leq b \quad \forall x \in C,$$

$$a^T x \geq b \quad \forall x \in D.$$

15.2 支撑超平面 (Supporting Hyperplane)

定理 33: 支撑超平面

设 $C \subseteq \mathbb{R}^n$ 是非空凸集, $x_0 \in \partial C$ (x_0 在 C 的边界上), 则存在非零向量 $a \in \mathbb{R}^n$ 使得

$$a^T(x - x_0) \leq 0 \quad \forall x \in C.$$

(即超平面 $\{x \mid a^T(x - x_0) = 0\}$ 在 x_0 处支撑 C)

注解 34: 分离与支撑超平面的作用

分离超平面用于证明两个不相交凸集的存在性, 支撑超平面则描述凸集在边界点的局部性质。两者在凸优化中是核心几何工具。